


Probabilistische Robotik: Briefkastenbeispiel



Beispiel

Ist Post da?

oder:

$$\mathbf{P}(S|E) = \frac{\mathbf{P}(E|S)\mathbf{P}(S)}{\mathbf{P}(E)}$$

- Für Briefkasten betrachte ZV S (Status) mit $\mathcal{D}(S) = \{l(eer), v(oll)\}$
- Evidenzen E mit $\mathcal{D}(E) = \{e_l, e_v\}$
- Gegeben (lange Erfahrung!) seien:
 $\mathbf{P}(S) = \langle P(l), P(v) \rangle = \langle 0.5, 0.5 \rangle$;
 $\mathbf{P}(E|S) = \langle P(e_l|l), P(e_l|v), P(e_v|v), P(e_v|l) \rangle$
 $= \langle 0.7, 0.2, 0.8, 0.3 \rangle$

$$\text{z.B.: } P(l|e_l) = \frac{P(e_l|l)P(l)}{P(e_l)} = \frac{0,7 \cdot 0,5}{P(e_l)}$$

Kennen wir $P(e_l)$? Ja: $P(e_l) = P(e_l|l)P(l) + P(e_l|v)P(v) = 0,35 + 0,1$

Marginalisierung

$$\rightarrow P(l|e_l) = 0,7778$$

Löst „schärfer Hingucken“ Unsicherheit auf?

Extrembeispiel: Benutze dieselbe Information mehrmals!

↳ Intuition sagt: das kann nichts bringen!

W'theorie sagt: Stimmt!

$$P(a|b,b) = P(a|b)P(b|b) = P(a|b)$$

Messungen müssen (statistisch) unabhängig sein!

$$P(a \cap b) = P(a) \cdot P(b) \quad \text{also } P(a|b)=P(a) \text{ und } P(b|a)=P(b)$$

- Messungen „desselben“ an derselben Stelle sind abhängig
- Modelliere alle Messungen 1 Zustands als 1 Messung
- Auch konsekutive Messungen auf Robotern
(z.B. bei Lokalisierung) sind statistisch meist nicht unabhängig
- Praktisch kümmert man sich meist nicht darum!

Bayes-Filter allgemein: Modell (1/2)

Gesucht: Evidenzbasierte Zustandsschätzung „rekursiver Zustandsschätzer“

$$\mathbf{P}(\mathbf{X}_{t+1} | \mathbf{e}_{1:t+1}) = f(\mathbf{e}_{1:t+1}, \mathbf{P}(\mathbf{X}_t | \mathbf{e}_{1:t}))$$

... für irgendeine Fkt. f und **Evidenzen** (Aktion oder Messung) \mathbf{e}

Ansatz

$$\begin{aligned}\mathbf{P}(\mathbf{X}_{t+1} | \mathbf{e}_{1:t+1}) &= \mathbf{P}(\mathbf{X}_{t+1} | \mathbf{e}_{1:t}, \mathbf{e}_{t+1}) \\ &= \eta \cdot \mathbf{P}(\mathbf{e}_{t+1} | \mathbf{X}_{t+1}, \mathbf{e}_{1:t}) \cdot \mathbf{P}(\mathbf{X}_{t+1} | \mathbf{e}_{1:t}) \quad [\text{Bayessche Regel}] \\ &= \eta \cdot \mathbf{P}(\mathbf{e}_{t+1} | \mathbf{X}_{t+1}) \cdot \mathbf{P}(\mathbf{X}_{t+1} | \mathbf{e}_{1:t}) \quad [\text{Markow-Annahme}]\end{aligned}$$

Filterung

Prädiktion
(s. nächste Folie)

Bayes-Filter allgemein: Modell (2/2)

Vereinfachung der Prädiktion

$$\begin{aligned} \mathbf{P}(\mathbf{X}_{t+1} | \mathbf{e}_{1:t}) &= \int_{\mathbf{x}_t} \left[\mathbf{P}(\mathbf{X}_{t+1} | \mathbf{x}_t, \mathbf{e}_{1:t}) \cdot \underbrace{P(\mathbf{x}_t | \mathbf{e}_{1:t})}_{\text{aktuelle W'keit f. Zust.}} \right] \\ &= \int_{\mathbf{x}_t} \left[\mathbf{P}(\mathbf{X}_{t+1} | \mathbf{x}_t) \cdot P(\mathbf{x}_t | \mathbf{e}_{1:t}) \right] \quad [\text{Markow-Annahme}] \end{aligned}$$

Zusammengefasst

$$\mathbf{P}(\mathbf{X}_{t+1} | \mathbf{e}_{1:t+1}) = \eta \cdot \mathbf{P}(\mathbf{e}_{t+1} | \mathbf{X}_{t+1}) \cdot \int_{\mathbf{x}_t} \left[\mathbf{P}(\mathbf{X}_{t+1} | \mathbf{x}_t) \cdot P(\mathbf{x}_t | \mathbf{e}_{1:t}) \right]$$

- So **nicht praktikabel** (kontinuierl. Verteilungen, Integration)
- Unterschiedliche Vereinfachungen/Approximationen möglich

Spezieller Bayes-Filter: Idee

Russell/Norvig, Kap.15.2


Voraussetzung: Roboterhandeln/Umgebungs-dynamik wird beschrieben als Folge von **abwechselnd** Aktion/Ereignis und Zustandsmessung. Gegeben Start-Zustandsschätzung,

1. Prädiktion: Sage resultierenden Zustand für Aktion/Ereignis voraus (**a-priori-Zustandsschätzung**)

(**z.B.** berechne erwartete Zielpose für Raddrehungen (Odometrie));
führe die Aktion aus (bzw. unabhängige Ereignis geschieht)

2. Filterung: Miss resultierenden Zustand; ggf. mach mehrere unabhängige Messungen (die sich widersprechen dürfen)

z.B. miss Pose durch Odometrie und durch Gyroskop;
berechne aktuelle Zustandsverteilung, die maximal gut zu allen Messungen und der Vorhersage passt
(**a-posteriori-Zustandsschätzung**); weiter bei 1.



Handeln und Messen

Zustand x :
gleichzeitige
Ausprägung der ZVn

- Erziele Unabhängigkeit durch Abwechseln von Messen-Handeln-Messen-Handeln-...
- **Konvention:** Sortiere Evidenzen in Aktionen (u_i), Messungen (z_i)
- **Konvention:** W'keit des Zustands x heißt $Bel(x)$ (*belief*)

$$Bel(x_t) := P(x_t | u_1, z_1, \dots, u_t, z_t)$$

- **Vereinfachung:** Diskrete Zustände \rightarrow ersetze \int durch \sum

Entsprechend dem
Bayes-Filter-Modell
(Folie 162) gilt:

$$Bel(x_t) = \eta \cdot P(z_t | x_t) \sum_{x_{t-1}} P(x_t | x_{t-1}, u_t) \cdot Bel(x_{t-1})$$

(statisches) Sensormodell (st.) Aktionsmodell

Briefkastenbeispiel, die Zweite

- Aktion *leeren* leert den Briefkasten (meistens):

$$\begin{aligned} P(S \mid \text{leeren}, S^-) &= \\ &= \langle P(l \mid \text{leeren}, v), P(v \mid \text{leeren}, v), P(l \mid \text{leeren}, l), P(v \mid \text{leeren}, l) \rangle \\ &:= \langle 0.8, 0.2, 1, 0 \rangle \end{aligned}$$

- Gelte für Anfangszustand x_0 :

$$Bel(x_0:S=v) = P(v) := 0.75$$

- Führe Aktion *leeren* zum Zustand x_1 . Dann gilt a priori:

$$\begin{aligned} Bel(x_1:S=l) &= \sum_S P(l \mid \text{leeren}, S) \cdot Bel(x_0:S) \\ &= P(l \mid \text{leeren}, v) \cdot P(v) + P(l \mid \text{leeren}, l) \cdot P(l) \\ &= 0.8 \cdot 0.75 + 1 \cdot 0.25 = 0.85 \end{aligned}$$

$$Bel(x_1:S=v) = 1 - Bel(x_1:S=l) \quad (\text{Nachprüfen zur Übung!})$$

Hier Belief noch ohne Messung \rightarrow a-posteriori-Schätzung analog dem 1. Beispiel-Teil mit Normalisierung!

Algorithmus Bayes-Filter


Buch, Algorithmus 4.1

Eingabe : Aktueller Belief $Bel(x_t)$, sowie ein Paar (u, z) .


Ausgabe: Aktualisierter Belief $Bel(x_{t+1})$

```
1: for alle Zustände  $x_t$  do                                     // Update nach Aktion
2:    $\overline{Bel}(x_{t+1}) = \sum_{x_t} P(x_{t+1} | u, x_t) Bel(x_t)$ 
3: end for
4:  $\eta = 0$ 
5: for alle Zustände  $x_{t+1}$  do                                   // Update nach Messung
6:    $Bel(x_{t+1}) = P(z | x_{t+1}) \overline{Bel}(x_{t+1})$ 
7:    $\eta = \eta + Bel(x_{t+1})$ 
8: end for
9: for alle Zustände  $x_{t+1}$  do                                   // Normierung
10:   $Bel(x_{t+1}) = \eta^{-1} Bel(x_{t+1})$ 
11: end for
12: return  $Bel(x_{t+1})$ 
```


Wo sind wir?



Kalman-Filter: Die Idee



Ausgangspunkte


- n -dimensionale Zustandsschätzung
z.B. Schätzung der Roboterpose in x, z, θ
- Lineares Fehlermodell für Aktionen
z.B. Schätzung des Posefehlers bei Bewegung;

www.cs.unc.edu/~welch/kalman/
Russell/Norvig, Kap.15.4
Thrun/Burgard/Fox Kap.3.2

Ziel

- Gib zu jedem Zeitpunkt aktuelle Zustandsschätzung
z.B. Poseschätzung in nächstem Zustand (vor/nach Aktion)
- Integriere Sensormessungen in Zustandsschätzung
z.B. Aktualisiere Poseschätzung nach Aktion+Gyro-Wert
- **Aktualisiere Fehlermodell optimal**
(bestmögliche Übereinstimmung mit bisherigen Aktionen+Messungen)

Kalman-Filter: Das Vorgehen




- 1. Prädiktion:** Sage resultierenden Zustand für Aktion/Ereignisvoraus;
schätze den Fehler nach aktuellem Fehlermodell ab;
führe die Aktion aus (bzw. unabhängiges Ereignis geschieht)
- 2. Filterung:** Miss resultierenden Zustand; ggf. mach mehrere unabhängige Messungen (die sich widersprechen dürfen);
nimm als aktuellen Zustand den an, der maximal gut zu allen Messungen und dem letzten Fehlermodell passt; aktualisiere Fehlermodell(!); weiter bei 1.

Beschränkung 1: Fehlermodell ist Normalverteilung!
Beschränkung 2: Zustandsverteilung ist Normalverteilung!
Ein Kalman-Filter ist ein spezieller Bayes-Filter

Ausführlich: Vorlesung von Kai Lingemann, 8.11.2012!

Wo sind wir jetzt?



BAYES & KALMAN
DEPT. OF ROBOTICS

4.4 Fusion von Odometriedaten


- Praktisch alle mobilen Roboter nutzen Odometriedaten („fast geschenkt!“)
- Normalerweise fusioniert mit anderen Messwerten
- Fusioniere mit solchen Messwerten, die unabhängig sind und anderen systematischen Fehlern unterliegen
- Fusionierung kann auf unterschiedliche Arten gehen (Kalman-Filter ist eine davon)
- In diesem Abschnitt Fusion von Odometriedaten mit
 1. Gyro-Daten („Gyrodometrie“)
 2. Laser-Winkelhistogrammen

Gyrodometrie

Quellen:

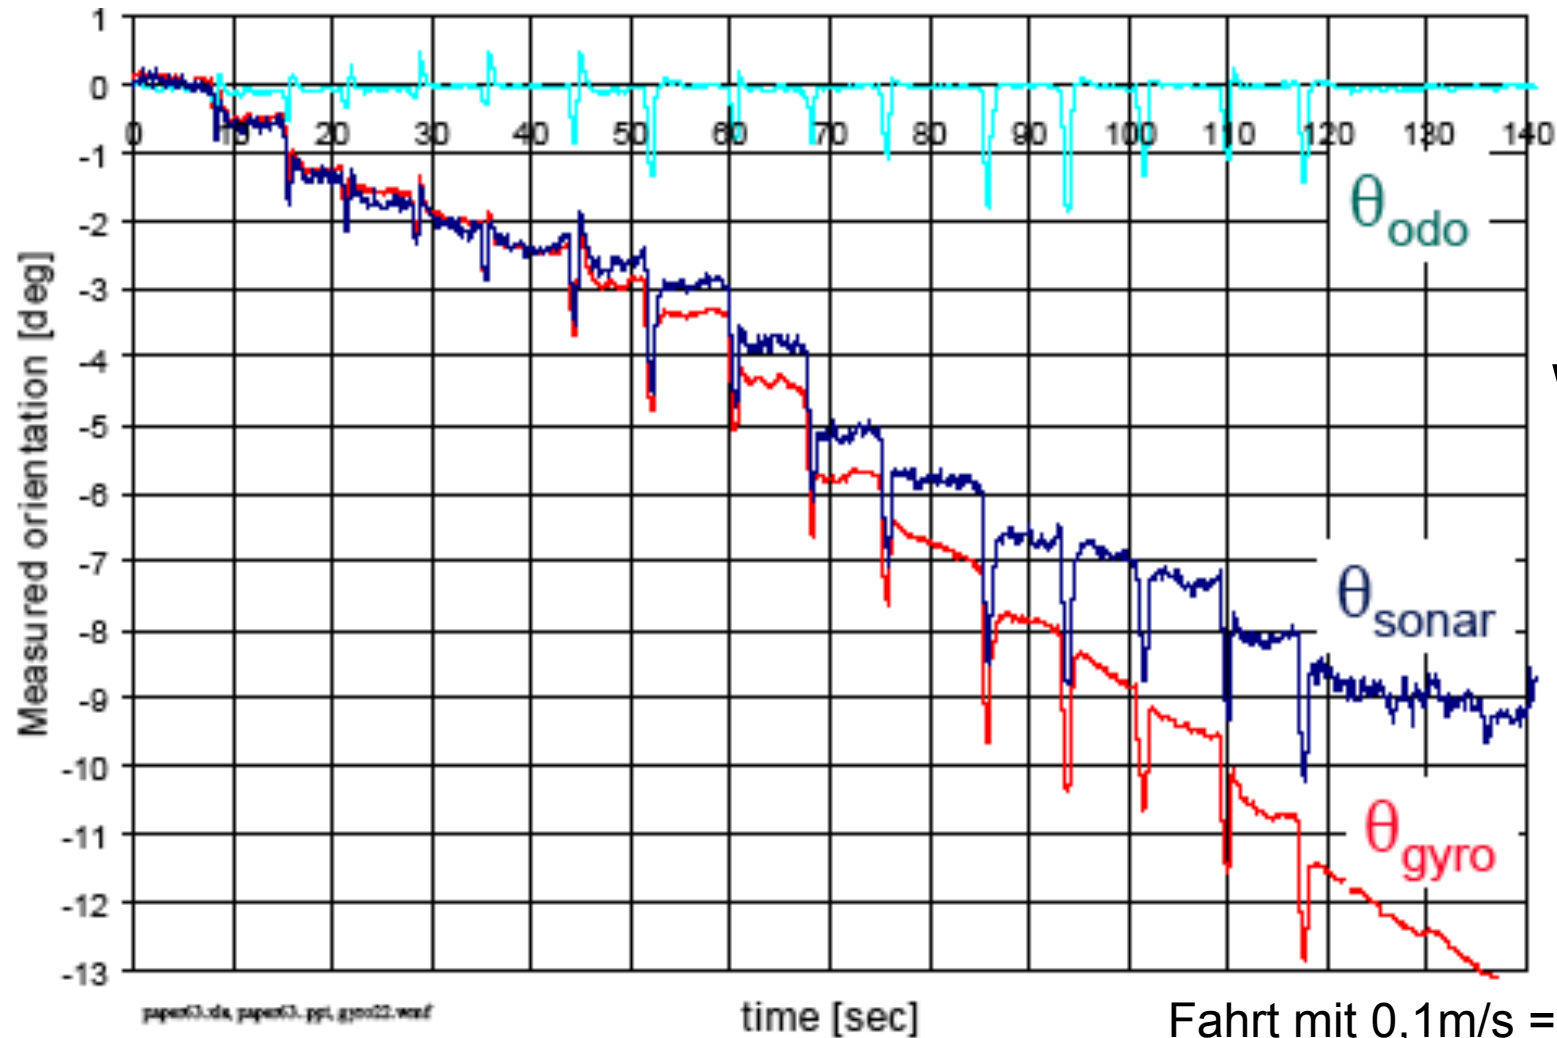
[Borenstein&Feng, ICRA-1996]
[Solda, Dipl.-Arbeit RWTH Aachen, 2003]

- Gyros unterliegen systematischer Drift
- Kurzfristig sind sie verlässlich, besonders auch bei Drehung
- Odometrie erzeugt kumulative Messfehler
- Die größten Messfehler entstehen an „kritischen“ Stellen:
 - Drehungen
 - „Holpern“ (z.B. Schwelle)
- **Idee: Deterministische Fusion**
 - Über kurze Zeit sollten beide dieselben Ergebnisse bringen (bis auf Rauschen)
 - Tritt kurzfristig Differenz auf, nimm verlässlicheren Wert



Messfehlerkumulation über Schwellen [Borenstein/Feng 1996]

9cm-Kabel schräg zur Fahrt in gleichen Abständen gelegt



Sonar/
Wandabstand
als *genuine
truth* bzgl.
Orientierung

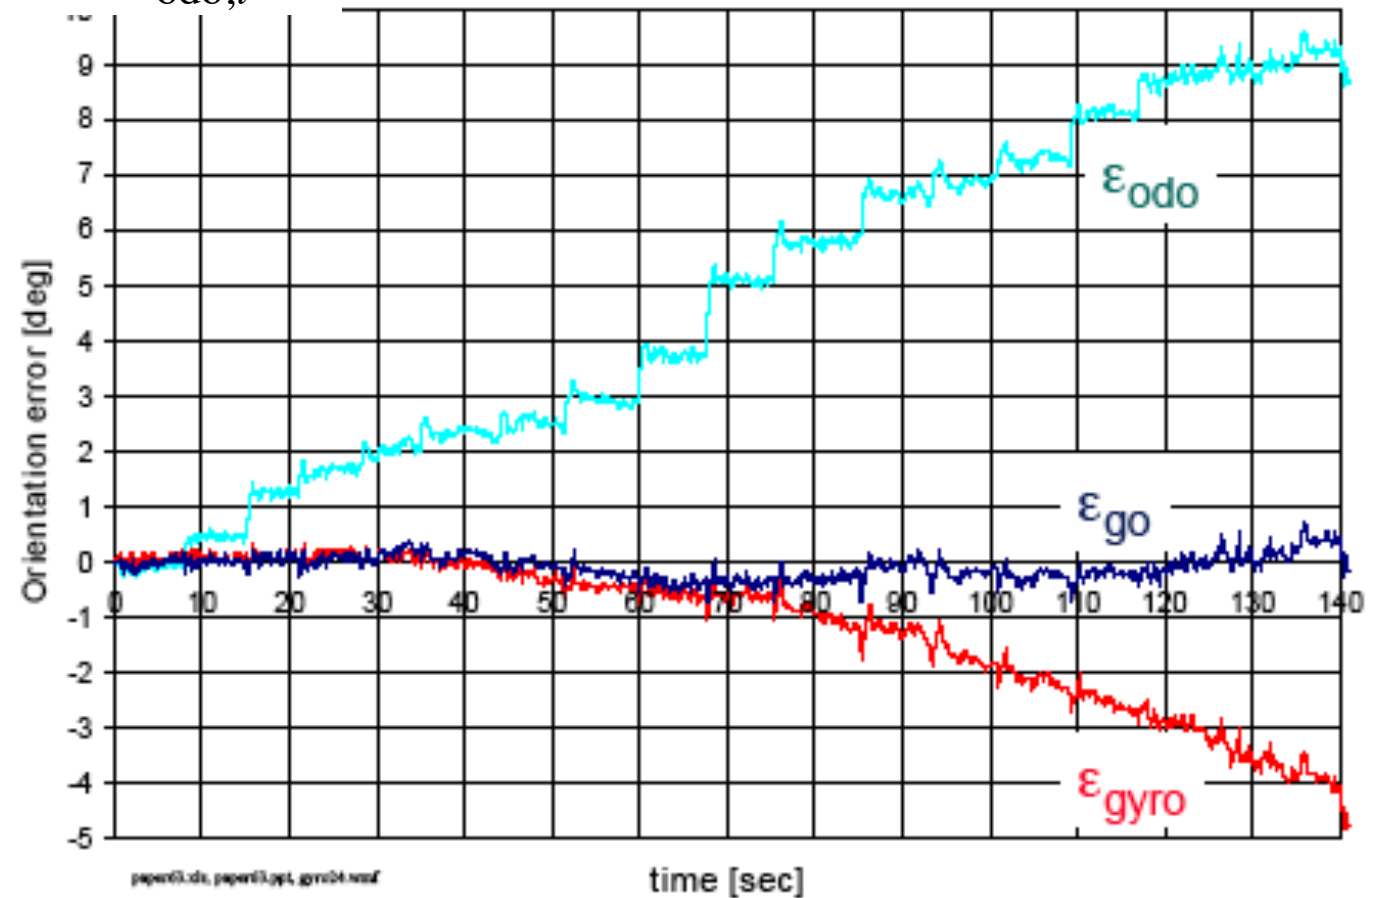
if $\left(\left| \Delta\theta_{\text{gyro},i} - \Delta\theta_{\text{odo},i} \right| > \Delta\theta_{\text{min}} \right)$

then $\theta_i := \theta_{i-1} + t\Delta\theta_{\text{gyro},i}$

else $\theta_i := \theta_{i-1} + t\Delta\theta_{\text{odo},i}$

Deterministische Korrektur

[Borenstein/ Feng 1996]



Algorithmus: Deterministische Gyrodometrie

Buch, Algorithmus 4.4

Eingabe : Rotationsschätzungen $\Delta\theta_{\text{gyro}}$, $\Delta\theta_{\text{odo}}$. Feste Schwellwerte γ_{odo} , γ_{gyro} für Odometrie resp. Gyroskop, sowie eine Aktualisierungs-Gewichtung α .

Ausgabe: Fusionierte Orientierung θ_{t+1} , Update der Schätzung von $\varepsilon_{\text{gyro}}$.

```
1: if  $|\Delta\theta_{\text{odo}}| > \gamma_{\text{odo}}$  or  
    $|\Delta\theta_{\text{gyro}} - \varepsilon_{\text{gyro}}| > \gamma_{\text{gyro}}$  then           // Kurvenfahrt laut Odometrie o. Gyroskop  
2:    $\Delta\theta_{\text{gyro}} = \Delta\theta_{\text{gyro}} - \varepsilon_{\text{gyro}}$            // Drift korrigieren  
3:    $\theta_{t+1} = \theta_t + \Delta\theta_{\text{gyro}}$            // Winkel nach Gyro  
4: else           // Fahrt relativ geradeaus  
5:    $\varepsilon_{\text{gyro}} = \alpha \cdot \varepsilon_{\text{gyro}} + (1 - \alpha) \cdot (\Delta\theta_{\text{gyro}} - \Delta\theta_{\text{odo}})$  // Drift aktualisieren  
6:    $\theta_{t+1} = \theta_t + \Delta\theta_{\text{odo}}$            // Winkel nach Odometrie  
7: end if  
8: return  $\theta_{t+1}, \varepsilon_{\text{gyro}}$ 
```
